

Informe Ejecutivo: Análisis de Comportamiento de Usuarios de Streaming

Alumno: Claramunt Federico

Repositorio: [Enlace a GitHub]

Aplicación: [Enlace a Streamlit Cloud]

1. Contexto y Objetivo

El presente proyecto analiza una base de datos de una plataforma de streaming con el fin de comprender el perfil demográfico y los hábitos de consumo de sus usuarios. El objetivo principal es identificar patrones que validen la estructura de los planes de suscripción y detectar oportunidades de negocio mediante técnicas de minería de datos, asegurando la trazabilidad y reproducibilidad de cada decisión técnica.

2. Dataset y Calidad Inicial

El conjunto de datos original contenía 8,160 observaciones y variables como edad, país, plan de suscripción y tiempo de visualización. En la inspección inicial (Notebook 01), se detectaron problemas críticos de calidad:

Inconsistencias de texto: Países registrados con códigos (ARG) o variaciones de mayúsculas (argentina vs Argentina) [Notebook 02].

Valores imposibles: Registros con edades de 150 años y minutos de visualización negativos [Notebook 02].

Ruido técnico: Presencia del valor "99,999" en minutos, distorsionando promedios [17, Notebook 02].

3. Decisiones de Limpieza y Preparación

Basándonos en la evidencia, se aplicó un pipeline de transformación (Notebook 02) que garantizó la integridad del análisis:

Normalización: Se unificaron los nombres de países y géneros bajo un formato estándar capitalizado.

Tratamiento de Nulos: Los valores faltantes en monthly_watch_time_mins se imputaron utilizando la mediana agrupada por plan, evitando sesgos por promedios distorsionados.

Filtrado: Se eliminaron registros con valores lógicos imposibles. El proceso resultó en un porcentaje de retención de datos del [X]%, registrado en el pipeline_log.csv.

4. Hallazgos del Análisis Exploratorio (EDA)

El análisis reveló que el público objetivo es mayoritariamente adulto joven (mediana de 33 años) [Notebook 03]. Entre los hallazgos principales destacan:

Validación de Negocio: Existe una correlación positiva entre el nivel del plan y el compromiso; los usuarios Premium presentan una mediana de consumo significativamente superior a los planes Básicos, justificando la segmentación de precios [Notebook 03].

Patrones Geográficos: Se identificaron preferencias marcadas por país, como una concentración inusual en el género "Documental" en mercados específicos, lo que orienta la adquisición de licencias regionales [Notebook 03].

5. Reducción de Dimensionalidad (PCA)

Se aplicó PCA sobre las variables numéricas (age, monthly_watch_time_mins, customer_support_tickets) previa estandarización obligatoria con StandardScaler.

Retención de Información: Con los primeros [X] componentes se logró explicar más del 80% de la varianza total [Notebook 04].

Interpretación: El PC1 se interpreta como un Índice de Intensidad de Uso, mientras que el PC2 captura la Fricción del Usuario (tickets de soporte), permitiendo simplificar el análisis de perfiles sin pérdida crítica de información [Notebook 04].

6. Conclusiones y Limitaciones

Conclusión: La plataforma atrae usuarios de alto consumo en sus niveles superiores, validando su modelo de escalabilidad. El comportamiento del usuario es predecible a partir de su nivel de suscripción más que por su ubicación geográfica [Notebook 05].

Limitaciones: La ausencia de variables socioeconómicas (ingresos) limita el análisis de elasticidad de precio.

Mejoras Futuras: Se recomienda implementar algoritmos de Clustering sobre los componentes principales obtenidos para automatizar la personalización de contenidos